

Machine Learning

군집화: 비슷한 데이터들끼리 묶음 하지만 분류와 다르게 분류 클래스는 정해지지 않음
 밀도 추정: 데이터로 벡터 공간에 가질 수 있는 모든 값의 확률을 추정
 차원 축소: 여러 차원들 중 가장 중요한 몇 개의 차원들만 사용
 → 회귀, 분류
 → 군집화, 밀도 추정, 차원 축소

1. 유형

	X (입력값, 특징벡터, input)	Y (출력값, 목표값, output)
지도 학습	○	○
비지도 학습	○	×
준지도 학습	○	대부분 있음

강화 학습: 에이전트가 한 행동에 대해 환경이 보상과 상태를 반환하고 보상이 증가하는 방향으로 행동 학습

회귀 vs 분류: 회귀는 출력값이 실수, 분류는 클래스
 매니폴드 가정: 고차원의 데이터에서 출력값에 영향을 주는 몇몇 중요 특징들이 있다

2. Dataset

훈련집합: 모델 학습을 위한 데이터
 검증집합: 학습이 제대로 되었는지 확인하기 위한 데이터
 테스트 집합: 실제로 출력값을 예측하기 위한 데이터
 통상적으로 데이터 셋의 크기는 특징 공간에 비해 매우 작다. → 데이터를 효과적으로 이용할 필요가 있다.

3. 비용 함수

$$E(x) \text{ MSE (Mean Square Error) } / J(\theta) = \frac{1}{2N} \sum_{i=1}^N (h_{\theta}(x^{(i)}) - y^{(i)})^2 \rightarrow \text{평균 제곱 오차}$$

↓ 오차

비용 함수가 linear Model 일 경우 해석적인 방법을 이용하면 되나, 고차원인 경우에는 경사 하강법과 같은 반복적인 방법을 통해 최적화를 해야 한다.

Linear Algebra Remind

1. Tensor (텐서)

3차원 이상의 고차원 수 배열

2. Matrix Multiplication (행렬 곱)

$A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times p}$ (곱해지도록 행렬의 열과 곱하는 행렬의 행이 같아야 함)

$$AB = C \in \mathbb{R}^{m \times p}, C_{ij} = \sum_{k=1}^n A_{ik} \times B_{kj}$$

3. 행렬의 수학적 성질

$$\left. \begin{aligned} A(BC) &= (AB)C \\ A(B+C) &= AB+AC \\ AB &\neq BA \end{aligned} \right\} \rightarrow \text{결합분배 법칙은 성립하지만 교환법칙은 성립하지 않음}$$

4. 대각합 / 성질

$$\left. \begin{aligned} \text{tr} A &= \sum_{i=1}^n A_{ii} \\ \text{정사각 행렬 } A \text{ 에 대해 } \text{tr} A &= \text{tr} A^T \\ \text{tr}(A+B) &= \text{tr} A + \text{tr} B \\ \text{tr}(tA) &= t \text{tr}(A) \\ \text{정사각 행렬 } A, B \text{ 에 대해 } \text{tr}(AB) &= \text{tr}(BA) \\ \text{정사각 행렬 } ABC \text{ 에 대해 } \text{tr}(ABC) &= \text{tr}(BCA) = \text{tr}(CAB) \end{aligned} \right\}$$

$$\begin{aligned} \text{LH저} \quad XY &= [x_1, x_2, \dots, x_n] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \sum_{i=1}^n x_i y_i \\ \text{오른} \quad XY^T &= \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} [y_1, y_2, \dots, y_n] = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \dots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \dots & x_2 y_n \\ \vdots & \vdots & \ddots & \vdots \\ x_n y_1 & x_n y_2 & \dots & x_n y_n \end{bmatrix} \end{aligned}$$

5. 선형 독립

벡터의 집합 $\{x_1, x_2, \dots, x_n\} \subset \mathbb{R}^m$ 에 대해 어떤 벡터가 다른 벡터들의 선형결합으로 표현된다면 선형 종속이라고 하고 그렇지 않다면 선형 독립이라고 한다

$$\hookrightarrow x_n = \sum_{i=1}^{n-1} a_i x_i$$

6. 공간

벡터의 집합 $\{x_1, x_2, \dots, x_n\} \subset \mathbb{R}^m$ 에 대해 벡터들의 선형결합으로 표현되는 벡터들의 집합을 공간이라고 한다.

7. 역행렬/성질

정사각 행렬 A에 대해 $A^{-1}A = AA^{-1} = I$ 를 만족하는 A^{-1} 를 A의 역행렬이라고 하며 이때 A를 invertible 혹은 non-singular라고 한다.

$$\begin{cases} (A^{-1})^{-1} = A \\ (AB)^{-1} = B^{-1}A^{-1} \\ (A^{-1})^T = (A^T)^{-1} = A^{-T} \\ (A+B)^{-1} \neq A^{-1} + B^{-1} \end{cases}$$

선형변환
 $V = AX \quad (V \in \mathbb{R}^m, A \in \mathbb{R}^{m \times n}, X \in \mathbb{R}^n)$
 n차원 벡터 V를 m차원 벡터 X로 변환
 ex) 회전
 $Rot(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$

8. 가우스 소거법

선형방정식을 첨가행렬로 변환하고 3가지 연산을 통해 행 사다리꼴 형태로 만들어서 해를 구하는 방법

1. 2개의 행들을 교체한다.
2. 0이 아닌 상수 값을 행에 곱한다.
3. 한 행에 스칼라를 곱해 다른 행에 더한다.

ex) $2x_1 + x_2 - x_3 = 8$
 $-3x_1 - x_2 + 2x_3 = -11$
 $-2x_1 + x_2 + 2x_3 = -3$

$$\rightarrow \begin{bmatrix} 2 & 1 & -1 \\ -3 & -1 & 2 \\ -2 & 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 8 \\ -11 \\ -3 \end{bmatrix} \rightarrow \begin{bmatrix} 2 & 1 & -1 & 8 \\ -3 & -1 & 2 & -11 \\ -2 & 1 & 2 & -3 \end{bmatrix} \begin{matrix} L_1 \\ L_2 \\ L_3 \end{matrix}$$

$A \quad X = b$

$[A|b]$
 첨가행렬
 \downarrow

$2x_1 + x_2 - x_3 = 8 \rightarrow x_1 = 2$
 $x_2 + x_3 = 2 \rightarrow x_2 = 3$
 $x_3 = -1$

$\leftarrow \begin{bmatrix} 2 & 1 & -1 & 8 \\ 0 & 1 & 1 & 2 \\ 0 & 0 & 1 & -1 \end{bmatrix} \begin{matrix} L_1 \\ L_2 \\ L_3 \end{matrix} \xrightarrow{L_2 \rightarrow L_1 + 2L_2 - L_3} \begin{matrix} L_1 \\ L_2 \\ L_3 \end{matrix}$

9. Norm: 벡터의 크기

l_1 Norm (맨하튼 노름): $\|x\|_1 = \sum_{i=1}^n |x_i|$
 l_2 Norm (유클리드 노름): $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$

RANK

- Row Rank: 행 벡터들의 부분 집합 중 선형 독립인 가장 큰 부분 집합의 크기
 = Column Rank
 = Matrix Rank / if Matrix Rank = 행렬의 크기

10. Frobenius Norm: 행렬의 크기

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n A_{ij}^2}$$

11. 벡터의 각도

a, b가 이루는 각도 = 코사인 유사도 = $\frac{a \cdot b}{\|a\| \|b\|} = \cos \theta$

l_∞ Norm (맥스 노름) \hookrightarrow Full Rank
 $= \max_{i=1, \dots, n} |x_i|$
 l_p Norm (p 노름) $= \sum_{i=1}^n (|x_i|^p)^{\frac{1}{p}}$

12. 고유값, 고유벡터

어떤 행렬 A에 대해 $AX = \lambda X$ (λ 는 스칼라)를 만족하는 벡터 X가 존재한다면 λ 는 행렬 A의 고유값, X는 λ 에 대응하는 고유벡터라고 한다.

13. 고유값 분해
 선형 독립인 행렬 A 는 고유벡터를 열벡터로 가지는 행렬 P , 고유값을 대각성분으로 가지는 대각행렬 Δ 에 대해
 $A = P\Delta P^{-1}$ 을 만족한다.

<p>orthogonal vector $x^T y = 0$, if $\ x\ _2 = \ y\ _2 = 1 \rightarrow$ orthonormal // Matrix $V^T V = I = V V^T \Rightarrow V^{-1} = V^T$</p>	<p>직교하면 선형 독립이지만 역은 아님</p>
---	---

Projection
 $p^2 = p$