

Constrained Optimization

1. Equality Constraints : 등식 제한 조건

- 1) $f(x)$ 를 최소화하고
- 2) $g(x)=0$ 를 만족

2. Inequality Constraints : 부등식 제한 조건 제약 조건이 Active

- 1) $f(x)$ 를 최소화하고
- 2) $g(x) \leq 0$ 를 만족

$\rightarrow g(x)=0$, 경계에 존재

제약 조건이 Inactive

$\rightarrow g(x) < 0$, 경계 안쪽에 존재

\Rightarrow 제약 조건이 있느냐 없느냐 의미 X

$\lambda = 0$ 으로 설정해서 제약 조건을 무시

3. 라그랑주 함수법

등식 제한 조건 or Active 한 경우

$$f(x_1, x_2) = x_1^2 + x_2^2$$

$$g(x_1, x_2) = x_1 + x_2$$

$$L(x_1, x_2, \lambda) = x_1^2 + x_2^2 + \lambda(x_1 + x_2)$$

$$\frac{\partial L}{\partial x_1} = 2x_1 + \lambda = 0$$

$$\frac{\partial L}{\partial x_2} = 2x_2 + \lambda = 0$$

$$\frac{\partial L}{\partial \lambda} = x_1 + x_2 = 0$$

$$\Rightarrow (x_1, x_2) = (0.5, 0.5)$$

Inactive 한 경우

제약 조건이 없다고 생각하고 그냥 최소화

4. KKT 조건

$$\nabla_{\vec{x}} L(\vec{x}, \lambda) = 0 \quad \text{Active 한 경우}$$

$$g(x) \leq 0 \quad g(x) = 0, \lambda \geq 0 / \nabla \lambda L = 0$$

$$\lambda \geq 0 \quad \text{Inactive 한 경우}$$

$$\lambda g(x) = 0 \quad g(x) < 0, \lambda = 0$$

따라서 문제를 풀 때에는 $g(x)=0$ (Active), $\lambda=0$ (Inactive)인 모든 경우를 고려하여 풀이. Inactive 한 경우 $g(x) < 0$ 을 만족하고 결과는 Inactive한 경우를 따라감

5. Multiple Constraints : 제약 조건이 여러 개

그냥 제약 조건 개수만큼 변수가 있음

$$f(x)$$

$$g(x)=0$$

$$h(x)=0$$

$$L(x, \lambda, \mu)$$

6. Lagrangian Duality

원래문제(primal)를 새로운 문제(dual)로 변환

$$\text{primal: } \min_{\vec{x}} f(\vec{x}), g_i(\vec{x}) \leq 0 \quad (i=1, 2, \dots, m)$$

$$\text{dual: } \max_{\vec{\lambda} \in \mathbb{R}^m, \vec{\lambda} \geq 0} D(\vec{\lambda}) = \min_{\vec{x} \in \mathbb{R}^d} L(\vec{x}, \vec{\lambda}) \rightarrow \text{라그랑주 함수를 최소로 만드는 } \vec{x}$$

$$\nabla_{\vec{x}} L(\vec{x}, \vec{\lambda}) = 0 \Rightarrow \vec{x}^*$$

$$D(\vec{\lambda}) = L(\vec{x}^*, \vec{\lambda})$$

Ex) Primal: $\min_{\vec{x} \in \mathbb{R}^d} \vec{c}^T \vec{x}$ (Linear)

$$\vec{x} \in \mathbb{R}^d$$

$$\vec{A}\vec{x} \leq \vec{b}$$

$$\Rightarrow \mathcal{L}(\vec{x}, \vec{\lambda}) = \vec{c}^T \vec{x} + \vec{\lambda}^T (\vec{A}\vec{x} - \vec{b})$$

$$= (\vec{c} + \vec{A}^T \vec{\lambda})^T \vec{x} - \vec{\lambda}^T \vec{b}$$

$$\nabla_{\vec{x}} \mathcal{L}(\vec{x}, \vec{\lambda}) = \vec{c} + \vec{A}^T \vec{\lambda} = \vec{0}$$

$$D(\vec{\lambda}) = -\vec{\lambda}^T \vec{b}$$

$$\text{Dual: } \max_{\vec{\lambda} \in \mathbb{R}^m} -\vec{b}^T \vec{\lambda}$$

$$\vec{c} + \vec{A}^T \vec{\lambda} = \vec{0}$$

$$\vec{\lambda} \geq \vec{0}$$

$$\text{Primal: } \min_{\vec{x} \in \mathbb{R}^d} \frac{1}{2} \vec{x}^T \vec{Q} \vec{x} + \vec{c}^T \vec{x} \text{ (Quadratic)}$$

$$\vec{A}\vec{x} \leq \vec{b}$$

$$\mathcal{L}(\vec{x}, \vec{\lambda}) = \frac{1}{2} \vec{x}^T \vec{Q} \vec{x} + \vec{c}^T \vec{x} + \vec{\lambda}^T (\vec{A}\vec{x} - \vec{b})$$

$$= \frac{1}{2} \vec{x}^T \vec{Q} \vec{x} + (\vec{c} + \vec{A}^T \vec{\lambda})^T \vec{x} - \vec{\lambda}^T \vec{b}$$

$$\nabla_{\vec{x}} \mathcal{L}(\vec{x}, \vec{\lambda}) = \vec{Q} \vec{x} + \vec{c} + \vec{A}^T \vec{\lambda} = \vec{0}$$

$$\vec{x} = -\vec{Q}^{-1} (\vec{c} + \vec{A}^T \vec{\lambda})$$

$$\text{Dual: } \max_{\vec{\lambda} \in \mathbb{R}^m} -\frac{1}{2} (\vec{c} + \vec{A}^T \vec{\lambda})^T \vec{Q}^{-1} (\vec{c} + \vec{A}^T \vec{\lambda}) - \vec{\lambda}^T \vec{b}$$

$$\vec{\lambda} \geq \vec{0}$$

Support Vector Machine

1. Margin (여백)

결정 초평면에서 양쪽 class에 대한 여백을 최대화할수록 일반화 능력이 향상될 것이다

2. Linear SVM

Linear SVM에서의 Margin

$$\text{Margin} = 2s = \frac{2|\text{dist}(x)|}{\|\vec{w}\|_2} = \frac{2}{\|\vec{w}\|_2}$$

$d(x)$ (결정 초평면)에 상수를 곱해도 변하지 않는 성질을 이용해 $|d(x)|=1$

$$\text{Maximize: } J(\vec{w}) = \frac{2}{\|\vec{w}\|_2}$$

$$\text{Subject to: } \vec{w}^T \vec{x}_i + b \geq 0, \forall y_i = 1$$

$$\downarrow \text{여부} \quad \vec{w}^T \vec{x}_i + b \leq 0, \forall y_i = -1$$

$$\text{Minimize: } J(\vec{w}) = \frac{\|\vec{w}\|_2}{2}$$

$$\text{Subject to: } y_i (\vec{w}^T \vec{x}_i + b) - 1 \geq 0$$

$$\mathcal{L}(\vec{w}, b, \vec{\alpha}) = \frac{\|\vec{w}\|_2}{2} - \sum_i \alpha_i (y_i (\vec{w}^T \vec{x}_i + b) - 1)$$

KKT

$$\frac{\partial \mathcal{L}(\vec{w}, b, \vec{\alpha})}{\partial \vec{w}} = \vec{0}, \vec{w} = \sum_i \alpha_i y_i \vec{x}_i$$

$$\frac{\partial \mathcal{L}(\vec{w}, b, \vec{\alpha})}{\partial b} = 0, \sum_i \alpha_i y_i = 0$$

$$\alpha_i \geq 0$$

→ 결국 $\vec{\alpha}_i$ 와 Support Vector를 구하면 됨
 $\vec{\alpha}_i$ 와 \vec{x}_i 를 구하면 \vec{w} 구할 수 있고,
 \vec{w} 와 \vec{x}_i 를 구하면 b 구할 수 있다.

3. Support Vector

$y_i (\vec{w}^T \vec{x}_i + b) - 1 = 0$ 을 만족하는 \vec{x}_i

4. Wolfe Dual Problem

$$\text{Maximize: } \tilde{L}(\alpha) = \sum_{i=1}^n d_i \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n d_i d_j y_i y_j x_i^T x_j$$

$$\text{Subject to: } \sum_{i=1}^n d_i y_i \alpha_i = 0$$

$$\alpha_i \geq 0, i=1, 2, \dots, n$$

5. Soft Margin

Hard Margin과 달리 오분류 샘플을 허용

Slack 변수 도입

$$y_i(\tilde{w}^T x_i + b) \geq 1 - \xi_i$$

$$\text{Minimize: } J(\tilde{w}, \xi) = \frac{1}{2} \|\tilde{w}\|_2^2 + C \sum_{i=1}^n \xi_i$$

C는 하이퍼 파라미터

C↓ 여백의 비중 ↑ 여백 최대화

C↑ ξ의 비중 ↑ 오분류 샘플 최소화

$$\text{Subject to: } y_i(\tilde{w}^T x_i + b) \geq 1 - \xi_i$$

$$0 \leq \xi_i, i=1, 2, \dots, n$$

$$\text{Lagrangian } \mathcal{L}(\tilde{w}, b, \xi, \alpha, \beta) = \left(\frac{1}{2} \|\tilde{w}\|_2^2 + C \sum_{i=1}^n \xi_i \right) - \left(\sum_{i=1}^n \alpha_i (y_i(\tilde{w}^T x_i + b) - 1 + \xi_i) + \sum_{i=1}^n \beta_i \xi_i \right)$$

KKT

$$\frac{\partial \mathcal{L}}{\partial \tilde{w}} = 0, \tilde{w} = \sum_{i=1}^n d_i y_i x_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0, \sum_{i=1}^n d_i y_i = 0$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = 0, C = \alpha_i + \beta_i, i=1, 2, \dots, n$$

6. Radial Basis Function

$$\phi(x) = \|x - c\|$$

⇒ 어떤 고정점 c에서 입력 벡터 x까지의 거리에만 영향을 받는 함수

ex) Gaussian Function

$$\phi(x) = \exp\left(-\frac{\|x - c\|_2^2}{2\sigma^2}\right)$$

7. Traditional Method

공간 변환 + 선형 SVM을 통해 학습

↓ Nowadays

Kernel Function 이용

8. Kernel Function

$$K(x, z) = \phi(x) \cdot \phi(z) \text{ 인 } \phi \text{ 존재하면 } K \text{는 커널 함수}$$

$$\phi: L \rightarrow H(\text{공간 매핑})$$

$$K: L \times L \rightarrow \mathbb{R}(\text{커널 함수})$$

자주 쓰이는 커널 함수

$$\text{Polynomial: } K(x, z) = (x \cdot z + 1)^p$$

Gaussian

$$\text{Hyperbolic Tangent: } K(x, z) = \tanh(\alpha x \cdot z + \beta)$$

K_1, K_2 커널 함수라면

$$\alpha \cdot K_1 (\alpha > 0), K_1 + K_2, K_1 \cdot K_2$$