

Spring 2023

SWCON253: Machine Learning

Lecture 16  
Density Estimation

Jinwoo Choi  
Assistant Professor  
CSE, Kyung Hee University



# Contents

1. Density Estimation
2. Parametric Methods
3. Non-Parametric Methods
4. Gaussian Mixture Model (GMM)
5. EM Algorithm

## References

- "기계학습" by 오일석, "패턴인식" by 오일석



# 1. Density Estimation



# Density Estimation

## ◆ 밀도 추정 (Density Estimation)

- 어떤 점  $\mathbf{x}$ 에서 데이터가 발생할 확률, 즉 확률분포  $P(\mathbf{x})$ 를 구하는 문제
  - ★ 예를 들어, 그림에서  $P(\mathbf{x}_1) > P(\mathbf{x}_2) > P(\mathbf{x}_3)$
- 분류 모델이자 생성 모델 (Generative Model)
  - ★ 새로운 샘플을 생성할 수 있음

## ◆ Parametric Methods


- ML (Maximum Likelihood) Estimation
- MAP (Maximum A Posteriori) Estimation

## ◆ Non-Parametric Methods

- 파젠 창
- $k$ -최근접 이웃 추정

## ◆ Mixture Models

- Gaussian Mixture Model (GMM)



## 2. Parametric Methods

1. Parametric Methods
2. ML Estimation
3. MAP Estimation
4. ML vs. MAP



# Parametric Methods



# ML Estimation



$$\hat{\theta} = \arg \max_{\theta} P(\mathbb{X}|\theta)$$

likelihood of  $\theta$

$$P(\mathbb{X}|\theta) = P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n|\theta) = \prod_{i=1}^n P(\mathbf{x}_i|\theta)$$

$$\mathcal{L}(\theta) = \log P(\mathbb{X}|\theta) = \sum_{i=1}^n \log P(\mathbf{x}_i|\theta)$$

$$\hat{\theta} = \arg \max_{\theta} \mathcal{L}(\theta)$$




# ML Estimation (cont'd)



ML estimator for  
a Gaussian density

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \hat{\mu})(\mathbf{x}_i - \hat{\mu})^T$$



[Caution] Here, we assumed:

- Each samples ( $\mathbf{x}_i$ 's) are **independent** to each other.
- Each features ( $x_k$ 's) are **not independent** to each other.

$$p(\mathbf{x}_i | \Theta) = p(\mathbf{x}_i | \mu) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu)\right)$$

$$\ln p(\mathbf{x}_i | \mu) = -\frac{1}{2} (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma|$$

$$L(\mu) = -\frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) - N \left( \frac{d}{2} \ln 2\pi + \frac{1}{2} \ln |\Sigma| \right)$$

$$\frac{\partial L(\mu)}{\partial \mu} = \sum_{i=1}^N \Sigma^{-1} (\mathbf{x}_i - \mu) = 0$$

$$\Rightarrow \left[ \Sigma^{-1} \right] \left[ \sum_{i=1}^N \mathbf{x}_i - N \mu \right] = 0 \Rightarrow \hat{\mu} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$





# MAP Estimation



$$P(\theta | \mathcal{X})$$

$$\hat{\theta} = \arg \max_{\theta} P(\theta | \mathcal{X}) = \arg \max_{\theta} P(\mathcal{X} | \theta) P(\theta)$$

$$\longleftrightarrow \text{ML: } \hat{\theta} = \arg \max_{\theta} P(\mathcal{X} | \theta)$$


$$P(\mathcal{X} | \theta) = P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n | \theta) = \prod_{i=1}^n P(\mathbf{x}_i | \theta)$$

$$\log P(\mathcal{X} | \theta) P(\theta) = \log P(\mathcal{X} | \theta) + \log P(\theta) = \sum_{i=1}^n \log P(\mathbf{x}_i | \theta) + \log P(\theta)$$


$$\text{ML: } \sum_{i=1}^n \log P(\mathbf{x}_i | \theta)$$



# ML vs. MAP



$$\log P(\mathbb{X}|\mu) = \sum_{i=1}^n \log P(x_i|\mu)$$



$$\log(P(\mathbb{X}|\mu)P(\mu)) = \sum_{i=1}^n \log P(x_i|\mu) + \log P(\mu)$$

# 3. Non-Parametric Methods

1. Parametric vs. Non-parametric
2. Histogram Method
3. Parzen Window
4.  $k$ -Nearest Neighbors Estimation
5.  $k$ -Nearest Neighbors Classification



# Parametric vs. Non-Parametric


## ◆ Parametric Density Estimation

- 확률 분포가 유한개의 파라미터 (모수)로 표현되는 형태 (예: Gaussian, Exponential, Bernoulli, ...)
- 매개변수 추정: ML, MAP 방법 등

## ◆ Non-Parametric Density Estimation

- 확률 분포가 임의의 형태
  - ★ 유한개의 파라미터를 정할 수 없음
- 파체 창, k-최근접 이웃 추정 방법 등

K-NN



# Histogram Method



- ◆ 특징 공간을  $x$ 의 집합으로 분할한 다음, 칸에 있는 샘플의 빈도를 세어 아래 식으로 추정

$$P(x) = \frac{bin(x)}{n}$$

- ★  $bin(x)$ :  $x$ 가 속한 칸(bin)의 샘플 개수
- ★  $n$ : 전체 샘플의 개수
- ★ 예) 우측 그림에서,  $P(x_+) = 4/80 = 0.05$

## 문제점

- ★ 매끄럽지 못하고 계단 모양을 띠는 확률밀도함수가 됨
- ★ 칸의 크기와 위치에 민감함



## Parzen Window

### ◆ Histogram 방법을 확장해 보자


- 특징공간에서 임의의 위치  $\mathbf{x}$ 에서의 확률 값을 다음 식과 같이 구함

$$p_h(\mathbf{x}) = \frac{1}{n} \frac{k(\mathbf{x})}{h^d}$$


[illegible]

$\frac{1}{s^2} \cdot \frac{k(s)}{s} \rightarrow \frac{k(s)}{s^3}$  (or  $\frac{k(s)}{s^2}$ )  
 $\Rightarrow$  2nd order  
system (closed loop)  
 $\Rightarrow$  3rd order system

- ★  $h$ : 창의 크기
- ★  $k(x)$ :  $x$ 를 중심으로 한 창에 포함된 샘플의 개수
- ★  $n$ : 전체 샘플의 개수
- ★  $d$ :  $x$ 의 차원 (feature의 개수)



(a) 1 차원 특징 공간



(b) 2 차원 특징 공간

- 문제점

- ★ 여전히 매끄럽지 못함

- 해결책

- ★ 창 안의 샘플 분포를 나타내는 **가중치 함수(커널)**를 도입 (중앙에 가까울 수록 높은 가중치)
- ★ **부드러운 커널**을 사용하면 매끄러운 확률 분포를 얻을 수 있음

# Parzen Window (cont'd)

## ◆ Kernel Density Estimation (KDE)

- 특징공간에서 **샘플의 위치  $x$** 에 커널을 씌우고, 커널 안에 있는 샘플들의 가중합을 구함
- 부드러운 커널**을 사용하면 매끄러운 확률 분포를 얻을 수 있음

$$p_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i)$$

★  $K_h(x - x_i)$

$x_i$ 를 중심으로 하는 폭  $h$ 의 커널

$$K_h(x - x_i)$$




그림 6-10 히스토그램 방법(왼쪽)과 커널 밀도 추정법(오른쪽)의 비교

# Parzen Window (cont'd)

## ◆ Kernel Density Estimation (KDE) (cont'd)


- $K_h$ 는 표준 커널  $K$ 로부터 만들어 낼 수 있음

$$K_h(\mathbf{x}) = \frac{1}{h^d} K\left(\frac{\mathbf{x}}{h}\right)$$


$$K_h(\mathbf{x} - \mathbf{x}_i)$$

$$\begin{aligned} \Rightarrow P_h(\mathbf{x}) &= \frac{1}{n} \sum_{i=1}^n K_h(\mathbf{x} - \mathbf{x}_i) \\ &= \frac{1}{n h^d} \sum_{i=1}^n K\left(\frac{\mathbf{x} - \mathbf{x}_i}{h}\right) \end{aligned}$$


$$K(x) \Rightarrow K\left(\frac{x}{h}\right)$$
$$K\left(\frac{x - x_i}{h}\right)$$



(a) 계단 함수



(b) 가우시안 함수



$$K_h(x) = \frac{1}{h} \cdot K\left(\frac{x}{h}\right)$$



# Parzen Window (cont'd)

$$\frac{1}{N} \sum_{i=1}^N N(x - x_i)$$




그림 6-11 대역폭이 확률밀도함수 추정에 미치는 영향

$$h \ll \sigma$$


# k-Nearest Neighbors Estimation




$$P_k(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^k \mathbb{I}_{\mathcal{N}_k(\mathbf{x})}(\mathbf{x}_i)$$

cf) Parzen window

$$P(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n K\left(\frac{\mathbf{x} - \mathbf{x}_i}{h}\right)$$




(a) 1차원 특징 공간




(b) 2차원 특징 공간

그림 3.8 k-최근접 이웃 방법으로 확률 밀도 함수의 추정 (k=3일 때)



# k-Nearest Neighbors Classification



$$\hat{j} = \arg \max_{1 \leq j \leq c} P(\omega_j | \mathbf{x}) = \arg \max_{1 \leq j \leq c} k_j$$

Finding Neighbors & Voting for Labels



## [Algorithm] k-NN Classification

- 1) 훈련 샘플들 중에  $\mathbf{x}$ 와 가장 가까운  $k$ 개를 찾는다.
- 2) 찾은  $k$ 개 중 가장 빈도가 높은 class를 찾는다.
- 3) 여러  $k$ 에 대해 1)과 2)를 반복한 후, 가장 많은 vote를 얻은 class를 정답으로 한다.



# Contents

1. Density Estimation
2. Parametric Methods
3. Non-Parametric Methods
4. Gaussian Mixture Model (GMM)
5. EM Algorithm
6. Summary & Remarks

## References

- “기계학습” by 오일석, “패턴인식” by 오일석



# 4. Gaussian Mixture Model

1. Mixture Models
2. Gaussian Mixture Model (GMM)



# Mixture Models

## ◆ Density Estimation with Mixture Models

- 두 개 이상의 서로 다른 확률 분포의 혼합으로 데이터의 확률 분포를 모델링
- 요소 확률 분포로는 통상 Gaussian 분포를 사용 → Gaussian Mixture Model (GMM)

$$P(\mathbf{x}) = \sum_{k=1}^K \pi_k P(\mathbf{x} | \boldsymbol{\theta}_k)$$

$$\sum_{k=1}^K \pi_k = 1$$

선형결합

$$P(\mathbf{x}) = \underbrace{\pi_1 N(\mathbf{x} | \boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1) + \pi_2 N(\mathbf{x} | \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2)}_{(\pi_1 + \pi_2 = 1)}$$

- Example: *Single vs Mixture Gaussian*

$$P(\mathbf{x}) = N(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma})$$




그림 6-12 하나의 가우시안으로 밀도 추정





그림 6-13 가우시안 혼합으로 밀도 추정

# Gaussian Mixture Model

← Most Popular D

## ◆ Gaussian Mixture Model

- K개 Gaussian들의 선형 결합으로 확률 분포를 표현

$$P(\mathbf{x}) = \sum_{k=1}^K \pi_k N(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

$$\sum_{k=1}^K \pi_k = 1$$

- ★ Gaussian의 개수  $K$ 는 Hyper parameter

다변수 가우시안

- ★  $k^{th}$  Gaussian 분포:  $N(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = \frac{1}{(\sqrt{2\pi})^d \sqrt{|\boldsymbol{\Sigma}_k|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k)\right)$

quadratic Form

- ★ 추정할 파라미터:  $\boldsymbol{\theta} = \{(\pi_1, \boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1), \dots, (\pi_K, \boldsymbol{\mu}_K, \boldsymbol{\Sigma}_K)\}$

- $\pi_k$ :  $k^{th}$  Gaussian에 대한 혼합계수(혼합가중치)(사전확률)
- $\boldsymbol{\mu}_k$ :  $k^{th}$  Gaussian의 평균벡터
- $\boldsymbol{\Sigma}_k$ :  $k^{th}$  Gaussian의 공분산행렬

→ 이 가우시안 분포에서 데이터가  
발생할 확률



# Gaussian Mixture Model (cont'd)

## ◆ Estimation of $\Theta$

- $\Theta = \{(\pi_1, \mu_1, \Sigma_1), \dots, (\pi_K, \mu_K, \Sigma_K)\}$

- Single Gaussian의 ML 추정 결과(지난 강의 참조):

$$P(\mathbf{x}) = N(\mathbf{x} | \mu, \Sigma)$$

$$\hat{\theta}_{ML} = \arg \max_{\theta} \log P(\mathbf{X} | \theta)$$

$$\begin{aligned}\mu &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \\ \Sigma &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^T\end{aligned}$$



- Gaussian Mixture의 경우:

$$P(\mathbf{x}) = \sum_{k=1}^K \pi_k N(\mathbf{x} | \mu_k, \Sigma_k)$$

- ★ K쌍의  $(\mu_k, \Sigma_k)$ 들과  $\pi_k$ 들(파라미터)을 추정해야 함

- ★ 샘플이 어떤 Gaussian에 속하는 지(소속정보)를 모름

→ 소속정보 추정(Expectation)과 파라미터 추정(Maximization)을 번갈아 반복해 보자! (EM 알고리즘)





# 5. EM Algorithm

1. EM Algorithm
2. EM Algorithm for GMM



# EM Algorithm

## ◆ 소속정보와 파라미터를 번갈아 추정해 보자

Note: **K-Means Clustering** is also a kind of EM Algorithm

1) [파라미터 초기화] 파라미터( $\theta$ )를 모르므로 통상 난수로 초기화

★ GMM의 경우:  $\theta = \{(\pi_1, \mu_1, \Sigma_1), \dots, (\pi_K, \mu_K, \Sigma_K)\}$




2) [E단계] 각 샘플의 소속정보( $Z$ )를 추정

★  $Z = [z_{ki}]$ ,  $z_{ki}$ : 샘플  $x_i$ 가  $k$  분포에 소속될 확률

3) [M단계] 각 분포에 소속된 샘플들을 이용하여 파라미터( $\theta$ ) 갱신

★ 예:  $\hat{\theta}_{ML} = \arg \max_{\theta} \log P(X|\theta)$


4) Stop Condition을 만족할 때까지 2)와 3)을 반복




# EM Algorithm for GMM

## ◆ 파라미터( $\theta$ ) 초기화

- 난수로 초기화
- K-Means Clustering 결과를 이용하여 초기화
  - ★  $k^{th}$  Cluster에 속한 샘플들의 평균벡터(군집중심)와 공분산행렬을 구한다.
  - ★  $k^{th}$  Gaussian의 평균벡터와 공분산행렬을 위에서 구한 값으로 초기화한다.
  - ★  $k^{th}$  Gaussian의 혼합계수는 ( $k^{th}$  Cluster에 속한 샘플수)/(전체 샘플수)로 초기화 한다.



난수로 초기화



K-Means 군집화 결과를  
이용하여 초기화

→ 각 Gaussian의 혼합계수는 군집수 / 전체 샘플수  
(사실은 평균)

# EM Algorithm for GMM (cont'd)

문제풀이 내용

## ◆ [E단계] 소속정보( $z$ )의 추정

- **잠재변수**  $z_k$ 가 어떤 샘플이  $k^{th}$  Gaussian에 속하는지( $z_k = 1$ )아닌지( $z_k = 0$ )를 나타낸다고 하면,

- ★  $k^{th}$  Gaussian의 priori probability:  $\pi_k = P(z_k = 1)$

- ★  $k^{th}$  Gaussian의 likelihood:  $P(\mathbf{x}|z_k = 1) = N(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$

- **소속정보 행렬**  $\mathbf{Z} = [z_{ki}]$ 의 원소  $z_{ki}$ 를 주어진 샘플  $\mathbf{x}_i$ 가  $k^{th}$  Gaussian에 속할 확률로 정의하자.

- ★  $k^{th}$  Gaussian의 posteriori probability:  $z_{ki} = P(z_k = 1|\mathbf{x}_i)$

- ★ 베이지 정리를 이용하여 정리하면,

$$z_{ki} = P(z_k = 1|\mathbf{x}_i) = \frac{P(\mathbf{x}_i|z_k = 1)P(z_k = 1)}{P(\mathbf{x}_i)} = \frac{P(\mathbf{x}_i|z_k = 1)P(z_k = 1)}{\sum_{j=1}^K P(\mathbf{x}_i|z_j = 1)P(z_j = 1)}$$

⇒

$$z_{ki} = \frac{\pi_k N(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j N(\mathbf{x}_i|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}$$

이걸 하고 나면 소속정보 추정이 완료됨

Bayes' Theorem

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^K P(B|A_j)P(A_j)}$$



# EM Algorithm for GMM (cont'd)

## ◆ [M단계] 확률분포( $\theta$ )의 추정

- $\theta = \{(\pi_1, \mu_1, \Sigma_1), \dots, (\pi_K, \mu_K, \Sigma_K)\}$

- ★  $\pi_k$ :  $k^{th}$  Gaussian의 발생 확률(혼합 가중치)

- ★  $\mu_k$ :  $k^{th}$  Gaussian의 mean vector

- ★  $\Sigma_k$ :  $k^{th}$  Gaussian의 covariance matrix

- ML Estimation of  $\theta$ :

- ★ 각 샘플  $\mathbf{x}_i$ 의 발생 확률이 서로 독립이라 가정하면, (합리적인 가정)

The log-likelihood of  $\theta$ :  $\mathcal{L}(\theta) = \log P(\mathbb{X}|\theta) = \log P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n|\theta)$

$$= \log \prod_{i=1}^n P(\mathbf{x}_i|\theta) = \sum_{i=1}^n \log P(\mathbf{x}_i|\theta)$$

- ★ The GMM:  $P(\mathbf{x}|\theta) = \sum_{k=1}^K \pi_k N(\mathbf{x}|\mu_k, \Sigma_k)$

↪ numerical issue

안다 작은 수를 계속 곱하면  
컴퓨터에선 0이 될 수 있음

⇒  $\mathcal{L}(\theta) = \log P(\mathbb{X}|\theta) = \sum_{i=1}^n \log \left( \sum_{k=1}^K \pi_k N(\mathbf{x}_i|\mu_k, \Sigma_k) \right)$



Maximize



# EM Algorithm for GMM (cont'd)

## • (...계속) ML Estimation of $\theta$

Now the problem can be summarized as a **Constrained Optimization**:

$$\text{Maximize: } \mathcal{L}(\theta) = \sum_{i=1}^n \log\left(\sum_{k=1}^K \pi_k N(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\right)$$

$$\text{Subject to: } \sum_{k=1}^K \pi_k - 1 = 0$$

★ **Lagrangian:**  $L(\theta, \lambda) = \mathcal{L}(\theta) + \lambda(\sum_{k=1}^K \pi_k - 1)$

★ Differentiating  $L(\theta, \lambda)$  w.r.t.  $\boldsymbol{\mu}_k$ ,  $\boldsymbol{\Sigma}_k$ ,  $\pi_k$  and equating the results to 0 yields:

$$\frac{\partial L(\theta, \lambda)}{\partial \boldsymbol{\mu}_k} = 0$$



$$\Rightarrow \boldsymbol{\mu}_k = \frac{1}{n_k} \sum_{i=1}^n z_{ki} \mathbf{x}_i$$

← k번째 클러스터 (평균값으로) 속한 샘플의 평균

$$\frac{\partial L(\theta, \lambda)}{\partial \boldsymbol{\Sigma}_k} = 0$$



$$\Rightarrow \boldsymbol{\Sigma}_k = \frac{1}{n_k} \sum_{i=1}^n z_{ki} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T$$

← k번째 클러스터 (확률값으로) 속한 샘플의 공분산

$$\frac{\partial L(\theta, \lambda)}{\partial \pi_k} = 0$$



$$\Rightarrow \pi_k = \frac{n_k}{n}$$

← k번째 클러스터 분포의 확률값 (확률값) 양

$$\text{where } n_k = \sum_{i=1}^n z_{ki}$$

← k번째 클러스터 속한 샘플의 (확률값) 개수

ML estimator for  
a Gaussian density

$$\boldsymbol{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

$$\boldsymbol{\Sigma} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$$



# 6. Summary & Remarks

1. Summary of Density Estimation
2. Remarks: Density Estimation의 활용

$$L(\theta, \lambda) = \sum_{\bar{x}=1}^n \log \sum_{j=1}^k \pi_j N(x_{\bar{x}} | \mu_j, \Sigma_j) + \lambda \left( \sum_{j=1}^k \pi_j - 1 \right)$$

$$\frac{\partial L(\theta, \lambda)}{\partial \mu_k} = \sum_{\bar{x}=1}^n \frac{1}{\sum_{j=1}^k \pi_j N(x_{\bar{x}} | \mu_j, \Sigma_j)} \cdot \frac{\partial \sum_{j=1}^k \pi_j N(x_{\bar{x}} | \mu_j, \Sigma_j)}{\partial \mu_k} \\ \Rightarrow \frac{\partial}{\partial \mu_k} \pi_k N(x_{\bar{x}} | \mu_k, \Sigma_k)$$

$$= \sum_{\bar{x}=1}^n \frac{\pi_k N(x_{\bar{x}} | \mu_k, \Sigma_k)}{\sum_{j=1}^k \pi_j N(x_{\bar{x}} | \mu_j, \Sigma_j)} \frac{\partial}{\partial \mu_k} \frac{(x_{\bar{x}} - \mu_k)^2}{2 \Sigma_k} = \sum_{\bar{x}=1}^n p(z_k=1 | x_{\bar{x}}) \frac{\partial}{\partial \mu_k} \frac{(x_{\bar{x}} - \mu_k)^2}{2 \Sigma_k}$$

$$\Sigma_k^{-1} (x_{\bar{x}} - \mu_k) \uparrow \frac{\partial}{\partial \mu_k} \frac{(x_{\bar{x}} - \mu_k)^2}{2 \Sigma_k}$$



# Summary of Density Estimation

## Non-Parametric

$$P(\mathbf{x}) = \frac{\text{bin}(\mathbf{x})}{n}$$

$$P_k(\mathbf{x}) = \frac{1}{h^d} \frac{k(\mathbf{x})}{n}$$

$$P_h(\mathbf{x}) = \frac{1}{n h^d} \sum_{i=1}^n K\left(\frac{\mathbf{x} - \mathbf{x}_i}{h}\right)$$

$$P_k(\mathbf{x}) = \frac{1}{h(\mathbf{x})^d} \frac{k}{n}$$

HS togram

→ + Window

Histogram

+ Kernel ex) Gaussian

## Parametric

$$P(\mathbf{x}) = P(\mathbf{x}|\boldsymbol{\theta})$$

$$\hat{\boldsymbol{\theta}}_{ML} = \arg \max_{\boldsymbol{\theta}} \log P(\mathbb{X}|\boldsymbol{\theta})$$

$$\hat{\boldsymbol{\theta}}_{MAP} = \arg \max_{\boldsymbol{\theta}} \log P(\mathbb{X}|\boldsymbol{\theta}) P(\boldsymbol{\theta})$$

$$\begin{aligned} P(\mathbb{X}|\boldsymbol{\theta}) &= P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n|\boldsymbol{\theta}) \\ &= \prod_{i=1}^n P(\mathbf{x}_i|\boldsymbol{\theta}) \end{aligned}$$

Parameter Estimation

## Parametric Mixture GMM

$$\begin{aligned} P(\mathbf{x}) &= P(\mathbf{x}|\boldsymbol{\theta}) \\ &= \sum_{k=1}^K \pi_k P(\mathbf{x}|\boldsymbol{\theta}_k) \end{aligned}$$

$$\boldsymbol{\theta} = \{(\pi_1, \boldsymbol{\theta}_1), \dots, (\pi_K, \boldsymbol{\theta}_K)\}$$


$$\sum_{k=1}^K \pi_k = 1$$





# Density Estimation의 활용


## ◆ After Density Estimation




$$P(x) = \sum \pi_k \cdot P(x|\theta_k)$$

### ● Clustering (Classification)

$$\pi_k P(x|\theta_k) \leftarrow \pi_j P(x|\theta_j)$$



### ● Outlier (Anomaly) Detection



$$P(x) < \text{Threshold}$$

- Q: GMM과 (Gaussian) Kernel Density Estimation의 차이점은?

$$P(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

Gaussian = 샘플의 개수  $n$   
 Gaussian = 군집의 개수  $K$

$$P(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n K_h(\mathbf{x} - \mathbf{x}_i) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{\mathbf{x} - \mathbf{x}_i}{h}\right) = \frac{1}{nh^d} \sum_{i=1}^n \mathcal{N}\left(\frac{\mathbf{x} - \mathbf{x}_i}{h} | 0, 1\right)$$

