

딥러닝 과제05

- 1 softmax를 적용한 후 출력이 $(0.001, 0.9, 0.001, 0.098)^T$ 이고 레이블 정보가 $(0, 0, 0, 1)^T$ 일 때, 세 가지 목적함수, 평균제곱 오차, 교차 엔트로피, 로그우도를 계산하시오. (로그 우도의 경우 PPT 12쪽에 있는 목적함수를 사용하시오)

$$\begin{aligned} \text{MSE} &= \frac{1}{4} \sqrt{(0.001-0)^2 + (0.9-0)^2 + (0.001-0)^2 + (0.098-1)^2} = 0.3186 \\ \text{CE} &= -\log(1-0.001) - \log(1-0.9) - \log(1-0.001) - \log(0.098) = 6.6759 \\ \text{NLL} &= -\log 0.098 = 3.3511 \end{aligned}$$

- 2 [예제 5-1]에서 $\lambda = 0.1, \lambda = 0.5$ 일 때를 계산하고 λ 에 따른 효과를 설명하시오. 이때 [그림 5-21]을 활용하시오.

예제 5-1 리지 회귀

훈련집합 $\mathbf{X} = \{\mathbf{x}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 2 \\ 3 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}\}$, $\mathbf{y} = \{y_1 = 3.0, y_2 = 7.0, y_3 = 8.8\}$ 이 주어졌다고 가정하자. 특징 벡터가 2차원이므로 $d=2$ 이고 샘플이 3개이므로 $n=3$ 이다. 훈련집합으로 설계행렬 \mathbf{X} 와 레이블 행렬 \mathbf{y} 를 다음과 같이 쓸 수 있다.

$$\mathbf{X} = \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 3 & 3 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 3.0 \\ 7.0 \\ 8.8 \end{pmatrix}$$

이 값들을 식 (5.29)에 대입하여 다음과 같이 $\hat{\mathbf{w}}$ 을 구할 수 있다. 이때 $\lambda = 0.25$ 라 가정하자.

$$\hat{\mathbf{w}} = \left(\begin{pmatrix} 1 & 2 & 3 \\ 1 & 3 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 3 & 3 \end{pmatrix} + \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix} \right)^{-1} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 3 & 3 \end{pmatrix} \begin{pmatrix} 3.0 \\ 7.0 \\ 8.8 \end{pmatrix} = \begin{pmatrix} 1.4916 \\ 1.3607 \end{pmatrix}$$

따라서 하이퍼 평면은 $y = 1.4916x_1 + 1.3607x_2$ 이다. 새로운 샘플로 $\mathbf{x} = (5 \ 4)^T$ 가 입력되면 식 (5.30)을 이용하여 12.9009를 예측한다.

$$\hat{\mathbf{w}} = \left(\begin{pmatrix} 1 & 2 & 3 \\ 1 & 3 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 3 & 3 \end{pmatrix} + \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix} \right)^{-1} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 3 & 3 \end{pmatrix} \begin{pmatrix} 3.0 \\ 7.0 \\ 8.8 \end{pmatrix} = \begin{pmatrix} 1.6154 \\ 1.2788 \end{pmatrix} \quad \hat{\mathbf{w}} = \left(\begin{pmatrix} 1 & 2 & 3 \\ 1 & 3 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 3 & 3 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right)^{-1} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 3 & 3 \end{pmatrix} \begin{pmatrix} 3.0 \\ 7.0 \\ 8.8 \end{pmatrix} = \begin{pmatrix} 1.4 \\ 1.4 \end{pmatrix}$$

```
import numpy as np
a = [[1, 2, 3],
      [1, 3, 3]]
b = [[0.2, 0],
      [0, 0.2]]
c = [[3.0],
      [7.0],
      [8.8]]
print(np.matmul(np.matmul(np.linalg.inv(np.matmul(a, np.transpose(a)) + b), a), c))
[1.61538462]
[1.27884615]
```




그림 5-21 L2 놈을 사용한 가중치 감쇠 기법의 효과

L_2 놈을 사용하여 가중치 감소를 적용하면 θ 를 2λ 의 비율로 줄인 다음 업데이트 하는 것과 동일하다.

```
import numpy as np
a = [[1, 2, 3],
      [1, 3, 3]]
b = [[1, 0],
      [0, 1]]
c = [[3.0],
      [7.0],
      [8.8]]
print(np.matmul(np.matmul(np.linalg.inv(np.matmul(a, np.transpose(a)) + b), a), c))
[[1.4]
 [1.4]]
```

- 3 [알고리즘 5-5]의 Adam은 RMSProp에 식 (5.12)의 모멘텀을 적용하였다. RMSProp에 식 (5.13)의 네스테로프 모멘텀을 적용한 Nesterov_Adam 알고리즘을 작성하시오.

알고리즘 5-5 Adam

입력: 훈련집합 \mathbb{X} , \mathbb{Y} , 학습률 ρ , 모멘텀 계수 α_1 , 가중 이동 평균 계수 α_2

출력: 최적의 매개변수 $\tilde{\Theta}$

```

1  난수를 생성하여 초기해  $\Theta$ 를 설정한다.
2   $\mathbf{v} = \mathbf{0}, \mathbf{r} = \mathbf{0}$ 
3   $t = 1$ 
4  repeat
5  그레디언트  $\mathbf{g} = \frac{\partial J}{\partial \Theta}|_{\Theta}$ 를 구한다.  $\tilde{\Theta} = \Theta + \alpha_1 \mathbf{v}$ 
6   $\mathbf{v} = \alpha_1 \mathbf{v} - (1 - \alpha_1) \mathbf{g}$  // 속도 벡터  $\mathbf{g} = \frac{\partial J}{\partial \Theta}|_{\tilde{\Theta}}$ 
7   $\mathbf{v} = \frac{1}{1 - (\alpha_1)^t} \mathbf{v}$ 
8   $\mathbf{r} = \alpha_2 \mathbf{r} + (1 - \alpha_2) \mathbf{g} \odot \mathbf{g}$  // 그레디언트 누적 벡터
9   $\mathbf{r} = \frac{1}{1 - (\alpha_2)^t} \mathbf{r}$ 
10  $\Delta \Theta = -\frac{\rho}{\epsilon + \sqrt{\mathbf{r}}} \mathbf{v}$ 
11  $\Theta = \Theta + \Delta \Theta$ 
12  $t++$ 
13 until (멈춤 조건)
14  $\tilde{\Theta} = \Theta$ 

```

$$\left. \begin{aligned} \mathbf{v} &= \alpha \mathbf{v} - \rho \frac{\partial J}{\partial \Theta} \\ \Theta &= \Theta + \mathbf{v} \end{aligned} \right\} \dots (5.12)$$

$$\left. \begin{aligned} \Theta &= \Theta + \alpha \mathbf{v} \\ \mathbf{v} &= \alpha \mathbf{v} - \rho \frac{\partial J}{\partial \Theta} \Big|_{\tilde{\Theta}} \\ \Theta &= \Theta + \mathbf{v} \end{aligned} \right\} \dots ($$